Laboratorio di Linguaggi Formali e Traduttori Corso di Studi in Informatica A.A. 2018/2019

Viviana Patti e Jeremy Sproston Dipartimento di Informatica — Università degli Studi di Torino

Versione del 6 dicembre 2018

Sommario

Questo documento descrive le esercitazioni di laboratorio e le modalità d'esame del corso di *Linguaggi Formali e Traduttori* per l'A.A. 2018/2019.

Svolgimento e valutazione del progetto di laboratorio

È consigliato sostenere l'esame nella prima sessione d'esame dopo il corso.

Supporto on-line al corso e forum di discussione

Sulla piattaforma I-learn sono disponibili due forum: il primo è dedicato alla pubblicazioni di annunci e notizie di carattere generale, mentre il secondo è un forum di discussione dedicato per gli argomenti affrontati durante il corso. L'iscrizone al forum annunci è effettuata automaticamente, è possibile disiscriversi ma è consigliabile farlo solo a seguito del superamento dell'esame per poter sempre ricevere in modo tempestivo le comunicazioni effettuate dal docente.

Progetto di laboratorio

Il progetto di laboratorio consiste in una serie di esercitazioni assistite mirate allo sviluppo di un semplice traduttore. Il corretto svolgimento di tali esercitazioni presuppone una buona conoscenza del linguaggio di programmazione Java e degli argomenti di teoria del corso Linguaggi Formali e Traduttori.

Modalità dell'esame di laboratorio

Per sostenere l'esame a un appello è necessario prenotarsi. L'esame di laboratorio è **orale** e **individuale**, anche se il codice è stato sviluppato in collaborazione con altri studenti. Durante l'esame vengono accertati: il corretto svolgimento della prova di laboratorio; la comprensione della sua struttura e del suo funzionamento; la comprensione delle parti di teoria correlata al laboratorio stesso.

Note importanti

• Per poter discutere il laboratorio è *necessario* aver prima superato la prova scritta relativa al modulo di teoria. L'esame di laboratorio deve essere superato nella sessione d'esame in cui viene superato lo scritto, altrimenti lo scritto deve essere sostenuto nuovamente.

- La presentazione di codice "funzionante" non è condizione sufficiente per il superamento della prova di laboratorio. In altri termini, è possibile essere respinti presentando codice funzionante (se lo studente dimostra di non avere adeguata familiarità con il codice e i concetti correlati).
- Il progetto di laboratorio può essere svolto individualmente o in gruppi formati da al massimo 3 studenti. Anche se il codice è stato sviluppato in collaborazione con altri studenti, i punteggi ottenuti dai singoli studenti sono indipendenti. Per esempio, a parità di codice presentato, è possibile che uno studente meriti 30, un altro 25 e un altro ancora sia respinto.
- Dal momento che durante la prova è possibile che venga richiesto di apportare modifiche al codice del progetto, è opportuno presentarsi all'esame con un'adeguata conoscenza del progetto e degli argomenti di teoria correlati.

Calcolo del voto finale

I voti della prova scritta e della prova di laboratorio sono espressi in trentesimi. Il voto finale è determinato calcolando la media pesata del voto della prova scritta e del laboratorio , secondo il loro contributo in CFU (con una eventuale modifica nel caso in cui lo studente ha scelto di sostenere una prova orale), e cioè

$$voto \ finale = \frac{voto \ dello \ scritto \times 2 + voto \ del \ laboratorio}{3} \pm esito \ orale \ (facoltativo)$$

Validità del presente testo di laboratorio

Il presente testo di laboratorio è valido sino alla sessione di febbraio 2020.

1 Implementazione di un DFA in Java

Lo scopo di questo esercizio è l'implementazione di un metodo Java che sia in grado di discriminare le stringhe del linguaggio riconosciuto da un automa a stati finiti deterministico (DFA) dato. Il primo automa che prendiamo in considerazione, mostrato in Figura 1, è definito sull'alfabeto $\{0,1\}$ e riconosce le stringhe in cui compaiono almeno 3 zeri consecutivi.




Figura 1: DFA che riconosce stringhe con 3 zeri consecutivi.

L'implementazione Java del DFA di Figura 1 è mostrata in Listing 1. L'automa è implementato nel metodo scan che accetta una stringa s e restituisce un valore booleano che indica se la stringa appartiene o meno al linguaggio riconosciuto dall'automa. Lo stato dell'automa è rappresentato per mezzo di una variabile intera state, mentre la variabile i contiene l'indice del prossimo carattere della stringa s da analizzare. Il corpo principale del metodo è un ciclo che, analizzando il contenuto della stringa s un carattere alla volta, effettua un cambiamento dello stato dell'automa secondo la sua funzione di transizione. Notare che l'implementazione assegna il valore -1 alla variabile state se viene incontrato un simbolo diverso da 0 e 1. Tale valore non è uno stato valido, ma rappresenta una condizione di errore irrecuperabile.

Listing 1: Implementazione Java del DFA di Figura 1.

```
public class TreZeri
    public static boolean scan(String s)
        int state = 0;
        int i = 0;
        while (state >= 0 && i < s.length()) {</pre>
            final char ch = s.charAt(i++);
            switch (state) {
            case 0:
                if (ch == '0')
                   state = 1;
                else if (ch == '1')
                   state = 0;
                else
                   state = -1;
                break;
            case 1:
                if (ch == '0')
                   state = 2;
                else if (ch == '1')
                    state = 0;
                    state = -1;
                break;
            case 2:
                if (ch == '0')
                    state = 3;
                else if (ch == '1')
                   state = 0;
                else
                    state = -1;
                break;
            case 3:
                if (ch == '0' || ch == '1')
                   state = 3;
                    state = -1;
                break;
            }
        return state == 3;
    public static void main(String[] args)
        System.out.println(scan(args[0]) ? "OK" : "NOPE");
```

Esercizio 1.1. Copiare il codice in Listing 1, compilarlo e testarlo su un insieme significativo di stringhe, per es. "010101", "1100011001", "10214", ecc.

Come deve essere modificato il DFA in Figure 1 per riconoscere il linguaggio complementare, ovvero il linguaggio delle stringhe di 0 e 1 che **non** contengono 3 zeri consecutivi? Progettare e implementare il DFA modificato, e testare il suo funzionamento.

Esercizio 1.2. Progettare e implementare un DFA che riconosca il linguaggio degli identificatori in un linguaggio in stile Java: un identificatore è una sequenza non vuota di lettere, numeri, ed il simbolo di "underscore" _ che non comincia con un numero e che non può essere composto solo dal simbolo _. Compilare e testare il suo funzionamento su un insieme significativo di esempi.

Esercizio 1.3. Progettare e implementare un DFA che riconosca il linguaggio di stringhe che contengono un numero di matricola seguito (subito) da un cognome, dove la combinazione di matricola e cognome corrisponde a studenti del turno 2 o del turno 3 del laboratorio di Linguaggi Formali e Traduttori. Si ricorda le regole per suddivisione di studenti in turni:

- Turno 1: cognomi la cui iniziale è compresa tra A e K, e il numero di matricola è dispari;
- Turno 2: cognomi la cui iniziale è compresa tra A e K, e il numero di matricola è pari;
- Turno 3: cognomi la cui iniziale è compresa tra L e Z, e il numero di matricola è dispari;
- Turno 4: cognomi la cui iniziale è compresa tra L e Z, e il numero di matricola è pari.

Per esempio, "123456Bianchi" e "654321Rossi" sono stringhe del linguaggio, mentre "654321Bianchi" e "123456Rossi" no. Nel contesto di questo esercizio, un numero di matricola non ha un numero prestabilito di cifre (ma deve essere composto di almeno una cifra). Un cognome corrisponde a una sequenza di lettere, e deve essere composto di almeno una lettera. Quindi l'automa deve accettare le stringhe "2Bianchi" e "122B" ma non "654322" e "Rossi". Assicurarsi che il DFA sia minimo.

Esercizio 1.4. Modificare l'automa dell'esercizio precedente in modo che riconosca le combinazioni di matricola e cognome di studenti del turno 2 o del turno 3 del laboratorio, dove il numero di matricola e il cognome possono essere separati da una sequenza di spazi, e possono essere precedute e/o seguite da sequenze eventualmente vuote di spazi. Per esempio, l'automa deve accettare la stringa "654321 Rossi" e " 123456 Bianchi " (dove, nel secondo esempio, ci sono spazi prima del primo carattere e dopo l'ultimo carattere), ma non "1234 56Bianchi" e "123456Bia nchi". Per questo esercizio, i cognomi composti (con un numero arbitrario di parti) possono essere accettati: per esempio, la stringa "123456De Gasperi" deve essere accettato. Modificare l'implementazione Java dell'automa di conseguenza.

Esercizio 1.5. Progettare e implementare un DFA che, come in Esercizio 1.3, riconosca il linguaggio di stringhe che contengono matricola e cognome di studenti del turno 2 o del turno 3 del laboratorio, ma in cui il cognome precede il numero di matricola (in altre parole, le posizioni del cognome e matricola sono scambiate rispetto all'Esercizio 1.3). Assicurarsi che il DFA sia minimo.

Esercizio 1.6. Progettare e implementare un DFA che riconosca il linguaggio dei numeri binari (stringhe di 0 e 1) il cui valore è multiplo di 3. Per esempio, "110" e "1001" sono stringhe del linguaggio (rappresentano rispettivamente i numeri 6 e 9), mentre "10" e "111" no (rappresentano rispettivamente i numeri 2 e 7).

Suggerimento: usare tre stati per rappresentare il resto della divisione per 3 del numero.

Esercizio 1.9. Progettare e implementare un DFA che riconosca il linguaggio di stringhe che contengono il tuo nome e tutte le stringhe ottenute dopo la sostituzione di un carattere del nome con un altro qualsiasi. Ad esempio, nel caso di uno studente che si chiama Paolo, il DFA deve accettare la stringa "Paolo" (cioè il nome scritto correttamente), ma anche le stringhe "Pjolo", "caolo", "Pa%lo", "Paola" e "Parlo" (il nome dopo la sostituzione di un carattere), ma non "Eva", "Perro", "Pietro" oppure "P*o*o".

Esercizio 1.10. Progettare e implementare un DFA con alfabeto $\{/, *, a\}$ che riconosca il linguaggio di "commenti" delimitati da /* (all'inizio) e */ (alla fine): cioè l'automa deve accettare le stringhe che contengono almeno 4 caratteri che iniziano con /*, che finiscono con */, e che contengono una sola occorrenza della sequenza */, quella finale (dove l'asterisco della sequenza */ non deve essere in comune con quello della sequenza /* all'inizio,). Quindi l'automa deve accettare le stringhe "/****/", "/****/", "/****/", "/***/", "/***/", "oppure "/**/***/"."

Esercizio 1.11. Modificare l'automa dell'esercizio precedente in modo che riconosca il linguaggio di stringhe (sull'alfabeto {/,*,a}) che contengono "commenti" delimitati da /* e */, ma con la possibilità di avere stringhe prima e dopo come specificato qui di seguito. L'idea è che sia possibile avere eventualmente commenti (anche multipli) immersi in una sequenza di simboli dell'alfabeto. Quindi l'unico vincolo è che l'automa deve accettare le stringhe in cui un'occorrenza della sequenza /* deve essere seguita (anche non immediatamente) da un'occorrenza della sequenza della sequenza della sequenza di simboli senza commenti). Ad esempio, il DFA deve accettare le stringhe "aaa/***/aa", "aa/*a*a*/", "aaaa", "/****/", "/*aa*/", "*/a", "a/**/***a", "a/**/***a", "a/**/***a" oppure "aa/*aa". Implementare l'automa seguendo la costruzione vista in Listing 1.

2 Analisi lessicale

Gli esercizi di questa sezione riguardano l'implementazione di un analizzatore lessicale per un semplice linguaggio di programmazione. Lo scopo di un analizzatore lessicale è di leggere un testo e di ottenere una corrispondente sequenza di token, dove un token corrisponde ad un'unità lessicale, come un numero, un identificatore, un operatore relazionale, una parola chiave, ecc. Nelle sezioni successive, l'analizzatore lessicale da implementare sarà poi utilizzato per fornire l'input a programmi di analisi sintattica e di traduzione.

I token del linguaggio sono descritti nel modo illustrato in Tabella 1. La prima colonna contiene le varie categorie di token, la seconda presenta descrizioni dei possibili lessemi dei token, mentre la terza colonna descrive i nomi dei token, espressi come costanti numeriche.

Gli identificatori corrispondono all'espressione regolare $[a-zA-Z][a-zA-Z0-9]^*$, e i numeri corrispondono all'espressione regolare $0 \mid [1-9][0-9]^*$.

Un esempio di programma scritto con questi elementi è il seguente:

```
d:=300;
t:=10;
print(d*t)
```

L'analizzatore lessicale dovrà ignorare tutti i caratteri riconosciuti come "spazi" (incluse le tabulazioni e i ritorni a capo), ma dovrà segnalare la presenza di caratteri illeciti, quali ad esempio # o @.

Token	Pattern	Nome
Numeri	Costante numerica	256
Identificatore	Lettera seguita da lettere e cifre	257
Relop	Operatore relazionale (<,>,<=,>=,==,<>)	258
Case	case	259
When	when	260
Then	then	261
Else	else	262
While	while	263
Do	do	264
Assegnamento	:=	265
Print	print	266
Read	read	267
Disgiunzione	11	268
Congiunzione	&&	269
Negazione	!	33
Parentesi tonda sinistra	(40
Parentesi tonda destra)	41
Parentesi graffa sinistra	{	123
Parentesi graffa destra	}	125
Somma	+	43
Sottrazione	_	45
Moltiplicazione	*	42
Divisione	/	47
Punto e virgola	;	59
EOF	Fine dell'input	-1

Tabella 1: Descrizione dei token del linguaggio

L'output dell'analizzatore lessicale dovrà avere la forma $\langle token_0 \rangle \langle token_1 \rangle \cdots \langle token_n \rangle$. Ad esempio:

- per l'input d:=300; l'output sarà $\langle 257, d \rangle \langle 265, := \rangle \langle 256, 300 \rangle \langle 59 \rangle \langle -1 \rangle$;
- per l'input print (d*t) l'output sarà $\langle 266, \text{print} \rangle \langle 40 \rangle \langle 257, \text{d} \rangle \langle 42 \rangle \langle 257, \text{t} \rangle \langle 41 \rangle \langle -1 \rangle$;
- per l'input case when x>y then x:=0 else y:=0 l'output sarà $\langle 259, \mathrm{case} \rangle \langle 260, \mathrm{when} \rangle \langle 257, \mathrm{x} \rangle \langle 258, > \rangle \langle 257, \mathrm{y} \rangle \langle 261, \mathrm{then} \rangle \langle 257, \mathrm{x} \rangle \langle 265, := \rangle \langle 256, 0 \rangle \langle 262, \mathrm{else} \rangle \langle 257, \mathrm{y} \rangle \langle 265, := \rangle \langle 256, 0 \rangle \langle -1 \rangle;$
- per l'input while (cases<=printread) do cases:=cases+1 l'output sarà $\langle 263, \text{while} \rangle$ $\langle 40 \rangle$ $\langle 257, \text{cases} \rangle$ $\langle 258, <= \rangle$ $\langle 257, \text{printread} \rangle$ $\langle 41 \rangle$ $\langle 264, \text{do} \rangle$ $\langle 257, \text{cases} \rangle$ $\langle 265, := \rangle$ $\langle 257, \text{cases} \rangle$ $\langle 43 \rangle$ $\langle 256, 1 \rangle$ $\langle -1 \rangle$.

In generale, i token della Tabella 1 hanno un attributo: ad esempio, l'attributo del token $\langle 256, 300 \rangle$ è il numero 300, mentre l'attributo del token $\langle 259, \mathrm{case} \rangle$ è la stringa case. Si noti, però, che alcuni token della Tabella 1 sono senza attributo: ad esempio, il segno "per" (*) è rappresentato dal token $\langle 42 \rangle$, e la parentesi tonda destra ()) è rappresentata dal token $\langle 41 \rangle$.

Nota: l'analizzatore lessicale non è preposto al riconoscimento della *struttura* dei comandi del linguaggio. Pertanto, esso accetterà anche comandi "errati" quali ad esempio:

- 5+)
- (34+26((2+15-(27
- else 5 := print < case

Altri errori invece, come simboli non previsti o sequenze illecite (ad esempio nel caso dell'input 17&5, oppure dell'input | | |), devono essere rilevati.

Classi di supporto. Per realizzare l'analizzatore lessicale, si possono utilizzare le seguenti classi. Definiamo una classe Tag in Listing 2, utilizzando le costanti intere nella colonna Nome in Tabella 1 per rappresentare i nomi dei token. Per i token che corrispondono a un solo carattere (tranne < e >, che corrispondono a "Relop", cioè agli operatori relazionali), si può utilizzare il codice ASCII del carattere: ad esempio, il nome in Tabella 1 del segno di somma (+) è 43, il codice ASCII del +.

Listing 2: Classe Tag

```
public class Tag {
    public final static int
        EOF = -1, NUM = 256, ID = 257, RELOP = 258,
        CASE = 259, WHEN = 260, THEN = 261, ELSE = 262,
        WHILE = 263, DO = 264, ASSIGN = 265, PRINT = 266, READ = 267,
        OR = 268, AND = 269;
}
```

Definiamo una classe Token per rappresentare i token (una possibile implementazione della classe Token è in Listing 3). Definiamo inoltre la classe Word derivata da Token, per rappresentare i token che corrispondono agli identificatori, alle parole chiave, alle operatori relazionali e agli elementi della sintassi che consistono di più caratteri (ad esempio &&). Una possibile implementazione della classe Word è in Listing 4. Ispirandosi alla classe Word, si può estendere Listing 5 per definire una classe NumberTok per rappresentare i token che corrispondono ai numeri.

Listing 3: Classe Token

```
public class Token {
    public final int tag;
    public Token(int t) { tag = t; }
    public String toString() {return "<" + tag + ">";}
    public static final Token
        not = new Token('!'),
        lpt = new Token('('),
        rpt = new Token('('),
        rpg = new Token('('),
        rpg = new Token('('),
        rpg = new Token('('),
        minus = new Token('('),
        mult = new Token('(''),
        div = new Token('(''),
        semicolon = new Token('(''));
}
```

Listing 4: Classe Word

```
public class Word extends Token {
   public String lexeme = "";
   public Word(int tag, String s) { super(tag); lexeme=s; }
   public String toString() { return "<" + tag + ", " + lexeme + ">"; }
   public static final Word
      casetok = new Word(Tag.CASE, "case"),
      when = new Word(Tag.WHEN, "when"),
      then = new Word(Tag.THEN, "then"),
      elsetok = new Word(Tag.ELSE, "else"),
      whiletok = new Word(Tag.WHILE, "while"),
      dotok = new Word(Tag.DO, "do"),
      assign = new Word(Tag.ASSIGN, ":="),
```

```
print = new Word(Tag.PRINT, "print"),
  read = new Word(Tag.READ, "read"),
  or = new Word(Tag.OR, "||"),
  and = new Word(Tag.AND, "&&"),
  lt = new Word(Tag.RELOP, "<"),
  gt = new Word(Tag.RELOP, ">"),
  eq = new Word(Tag.RELOP, "=="),
  le = new Word(Tag.RELOP, "<="),
  ne = new Word(Tag.RELOP, "<>"),
  ge = new Word(Tag.RELOP, ">>"),
  ge = new Word(Tag.RELOP, ">>");
}
```

Listing 5: Classe NumberTok

```
public class NumberTok extends Token {
      // ... completare ...
}
```

Una possibile struttura dell'analizzatore lessicale (ispirata al testo [1, Appendice A.3]) è descritta nella classe Lexer in Listing 6.

Listing 6: Analizzatore lessicale di comandi semplici

```
import java.io.*;
import java.util.*;
public class Lexer {
   public static int line = 1;
   private char peek = ' ';
   private void readch(BufferedReader br) {
       try {
           peek = (char) br.read();
        } catch (IOException exc) {
           peek = (char) -1; // ERROR
    }
   public Token lexical_scan(BufferedReader br) {
        while (peek == ' ' || peek == '\t' || peek == '\n' || peek == '\r') {
            if (peek == '\n') line++;
            readch (br);
        switch (peek) {
            case '!':
               peek = ' ';
                return Token.not;
        // ... gestire i casi di (, ), {, }, +, -, *, /, ; ... //
            case '&':
                readch(br);
                if (peek == '&') {
                   peek = ' ';
                    return Word.and;
                } else {
                    System.err.println("Erroneous character"
                       + " after & : " + peek );
```

```
return null;
    // ... gestire i casi di ||, <, >, <=, >=, ==, <>, := ... //
        case (char)-1:
            return new Token(Tag.EOF);
        default:
            if (Character.isLetter(peek)) {
    // ... gestire il caso degli identificatori e delle parole chiave //
            } else if (Character.isDigit(peek)) {
    // ... gestire il caso dei numeri ... //
            } else {
                    System.err.println("Erroneous character: "
                           + peek );
                    return null;
            }
     }
public static void main(String[] args) {
    Lexer lex = new Lexer();
    String path = "...path..."; // il percorso del file da leggere
        BufferedReader br = new BufferedReader(new FileReader(path));
        Token tok;
        do {
            tok = lex.lexical_scan(br);
            System.out.println("Scan: " + tok);
        } while (tok.tag != Tag.EOF);
        br.close();
    } catch (IOException e) {e.printStackTrace();}
```

Esercizio 2.1. Si scriva in Java un analizzatore lessicale che legga da file un input e stampi la sequenza di token corrispondente. Per questo esercizio, si possono utilizzare senza modifica le classi Tag, Token e Word. Invece le classi NumberTok e Lexer devono essere completate.

Esercizio 2.2. Consideriamo la seguente nuova definizione di identificatori: un identificatore è una sequenza non vuota di lettere, numeri, ed il simbolo di "underscore" _ ; la sequenza non comincia con un numero e non può essere composta solo dal simbolo _. Più precisamente, gli identificatori corrispondono all'espressione regolare:

$$\left(\left[\mathtt{a}-\mathtt{z}\mathtt{A}-\mathtt{Z}\right]\bigm|\left({}_{-}({}_{-})^{*}[\mathtt{a}-\mathtt{z}\mathtt{A}-\mathtt{Z}\mathtt{0}-\mathtt{9}]\right)\right)\left(\left[\mathtt{a}-\mathtt{z}\mathtt{A}-\mathtt{Z}\mathtt{0}-\mathtt{9}\right]\bigm|{}_{-}\right)^{*}.$$

Estendere il metodo lexical_scan per gestire identificatori che corrispondono alla nuova definizione.

Esercizio 2.3. Estendere il metodo lexical_scan in modo tale che possa trattare la presenza di commenti nel file di input. I commenti possono essere scritti in due modi:

- commenti delimitati con /* e */;
- commenti che iniziano con // e che terminano con un a capo oppure con EOF.

I commenti devono essere ignorati dal programma per l'analisi lessicale; in altre parole, per le parti dell'input che contengono commenti, non deve essere generato nessun token. Ad esempio, consideriamo l'input seguente.

```
/* calcolare la velocita` */
d:=300; // distanza
t:=10; // tempo
print(d*t)
```

L'output del programma per l'analisi lessicale sarà $\langle 257, d \rangle \langle 265, := \rangle \langle 256, 300 \rangle \langle 59 \rangle \langle 257, t \rangle \langle 265, := \rangle \langle 256, 10 \rangle \langle 59 \rangle \langle 266, \text{print} \rangle \langle 40 \rangle \langle 257, d \rangle \langle 42 \rangle \langle 257, t \rangle \langle 41 \rangle \langle -1 \rangle.$

Oltre alle coppie di simboli /*, */ e //, un commento può contenere simboli che non fanno parte del pattern di nessun token (ad esempio, /*@#?*/ o /*calcolare la velocita '*/). Se un commento di forma /* ... */ è aperto ma non chiuso prima della fine del file (si veda ad esempio il caso di input d:=300; /*distanza) deve essere segnalato un errore. Si noti che ci possono essere più commenti consecutivi non separati da nessun token, ad esempio:

```
d:=300; /*distanza*//*da Torino a Lione*/
```

Inoltre la coppia di simboli */, se scritta al di fuori di un commento, deve essere trattata dal lexer come il segno di moltiplicazione seguito dal segno di divisione (ad esempio, per l'input x*/y l'output sarà $\langle 257, x \rangle$ $\langle 42 \rangle$ $\langle 47 \rangle$ $\langle 257, y \rangle$ $\langle -1 \rangle$). In altre parole, l'idea è che in questo caso la sequenza di simboli */ non verrà interpretata come la chiusura di un commento ma come una sequenza dei due token menzionati.

3 Analisi sintattica

Esercizio 3.1. Si scriva un analizzatore sintattico a discesa ricorsiva che parsifichi espressioni aritmetiche molto semplici, composte soltanto da numeri non negativi (ovvero sequenze di cifre decimali), operatori di somma e sottrazione + e -, operatori di moltiplicazione e divisione * e /, simboli di parentesi (e). In particolare, l'analizzatore deve riconoscere le espressioni generate dalla grammatica che segue:

```
 \begin{array}{llll} \langle start \rangle & ::= & \langle expr \rangle \ {\tt EOF} \\ \langle expr \rangle & ::= & \langle term \rangle \ \langle exprp \rangle \\ \langle exprp \rangle & ::= & + \langle term \rangle \ \langle exprp \rangle \\ & | & - \langle term \rangle \ \langle exprp \rangle \\ & | & \varepsilon \\ \langle term \rangle & ::= & \langle fact \rangle \ \langle termp \rangle \\ \langle termp \rangle & ::= & \star \ \langle fact \rangle \ \langle termp \rangle \\ & | & / \ \langle fact \rangle \ \langle termp \rangle \\ & | & \varepsilon \\ \langle fact \rangle & ::= & (\ \langle expr \rangle \ ) \ | \ {\tt NUM} \\ \end{array}
```

Il programma deve fare uso dell'analizzatore lessicale sviluppato in precedenza. Si noti che l'insieme di token corrispondente alla grammatica di questa sezione è un sottoinsieme dell'insieme di token corrispondente alle regole lessicali della Sezione 2. Nei casi in cui l'input corrisponde alla grammatica, l'output deve consistere dell'elenco di token dell'input seguito da un

messaggio indicando che l'input corrisponde alla grammatica. Invece nei casi in cui l'input *non* corrisponde alla grammatica, l'output del programma deve consistere di un messaggio di errore (come illustrato nelle lezioni in aula) indicando la procedura in esecuzione quando l'errore è stato individuato.

Segue una possibile struttura del programma (ispirato al testo [1, Appendice A.8]).

Listing 7: Analizzatore sintattico di espressioni semplici

```
import java.io.*;
public class Parser {
   private Lexer lex;
    private BufferedReader pbr;
   private Token look;
    public Parser(Lexer 1, BufferedReader br) {
        lex = 1;
       pbr = br;
       move();
    void move() {
       look = lex.lexical_scan(pbr);
        System.out.println("token = " + look);
    void error(String s) {
        throw new Error("near line " + lex.line + ": " + s);
    void match(int t) {
        if (look.tag == t) {
           if (look.tag != Tag.EOF) move();
        } else error("syntax error");
    public void start() {
        // ... completare ...
        expr();
        match(Tag.EOF);
        // ... completare ...
    private void expr() {
        // ... completare ...
    private void exprp() {
       switch (look.tag) {
        case '+':
        // ... completare ...
    }
    private void term() {
       // ... completare ...
```

```
private void termp() {
    // ... completare ...
}

private void fact() {
    // ... completare ...
}

public static void main(String[] args) {
    Lexer lex = new Lexer();
    String path = "...path..."; // il percorso del file da leggere
    try {
        BufferedReader br = new BufferedReader(new FileReader(path));
        Parser parser = new Parser(lex, br);
        parser.start();
        System.out.println("Input OK");
        br.close();
    } catch (IOException e) {e.printStackTrace();}
}
```

Esercizio 3.2. Segue una grammatica per un semplice linguaggio di programmazione, dove i terminali della grammatica corrispondono ai token descritti in Sezione 2 (in Tabella 1). Si noti che RELOP corrisponde a un elemento dell'insieme $\{==,<>,<=,>=,<,>\}$. Scrivere un analizzatore sintattico a discesa ricorsiva per la grammatica.

```
\langle prog \rangle ::= \langle statlist \rangle \text{ EOF}
      \langle statlist \rangle ::= \langle stat \rangle \langle statlistp \rangle
   \langle statlistp \rangle ::= ; \langle stat \rangle \langle statlistp \rangle \mid \varepsilon
            \langle stat \rangle ::= ID := \langle expr \rangle
                                        print (\langle expr \rangle)
                                        read (ID)
                                        case \langle whenlist \rangle else \langle stat \rangle
                                        while (\langle bexpr \rangle) \langle stat \rangle
                                        \{ \langle statlist \rangle \}
   \langle whenlist \rangle ::= \langle whenlist p \rangle \langle whenlist p \rangle
\langle whenlistp \rangle
                            ::=
                                        \langle whenitem \rangle \langle whenlistp \rangle \mid \varepsilon
\langle whenitem \rangle
                           ::=
                                       when (\langle bexpr \rangle) \langle stat \rangle
         \langle bexpr \rangle
                           ::=
                                        \langle expr \rangle RELOP \langle expr \rangle
          \langle expr \rangle ::= \langle term \rangle \langle exprp \rangle
                                        +\langle term \rangle \langle exprp \rangle \mid -\langle term \rangle \langle exprp \rangle \mid \varepsilon
         \langle exprp \rangle
                            ::=
                                       \langle fact \rangle \langle termp \rangle
          \langle term \rangle ::=
                                       \star \langle fact \rangle \langle termp \rangle \mid / \langle fact \rangle \langle termp \rangle \mid \varepsilon
       \langle termp \rangle ::=
            \langle fact \rangle ::= (\langle expr \rangle) \mid NUM \mid ID
```

4 Traduzione diretta dalla sintassi

Esercizio 4.1 (Valutatore di espressioni semplici). Modificare l'analizzatore sintattico dell'esercizio 3.1 in modo da valutare le espressioni aritmetiche semplici, facendo riferimento allo schema di traduzione diretto dalla sintassi seguente:

```
 \langle start \rangle \; ::= \; \langle expr \rangle \; \text{EOF} \; \{ \; print(expr.val) \; \}   \langle expr \rangle \; ::= \; \langle term \rangle \; \{ \; exprp.i = term.val \; \} \; \langle exprp \rangle \; \{ \; exprp.val = exprp.val \; \}   \langle exprp \rangle \; ::= \; + \langle term \rangle \; \{ \; exprp_1.i = exprp.i + term.val \; \} \; \langle exprp_1 \rangle \; \{ \; exprp.val = exprp_1.val \; \}   | \; - \langle term \rangle \; \{ \; exprp_1.i = exprp.i - term.val \; \} \; \langle exprp_1 \rangle \; \{ \; exprp.val = exprp_1.val \; \}   | \; \varepsilon \; \{ \; exprp.val = exprp.i \; \}   \langle term \rangle \; ::= \; \langle fact \rangle \; \{ \; termp.i = fact.val \; \} \; \langle termp \rangle \; \{ \; termp.val = termp.val \; \}   | \; \langle fact \rangle \; \{ \; termp_1.i = termp.i * fact.val \; \} \; \langle termp_1 \rangle \; \{ \; termp.val = termp_1.val \; \}   | \; \langle fact \rangle \; \{ \; termp.val = termp.i \; \}   | \; \varepsilon \; \{ \; termp.val = termp.i \; \}   | \; \varepsilon \; \{ \; termp.val = termp.i \; \}   | \; \langle fact \rangle \; ::= \; ( \; \langle expr \rangle \; ) \; \{ \; fact.val = expr.val \; \} \; | \; \text{NUM} \; \{ \; fact.val = \text{NUM.value} \; \}
```

Si noti che il terminale NUM ha l'attributo *value*, che è il valore numerico del terminale, fornito dall'analizzatore lessicale.

Una possibile struttura del programma è la seguente.

Nota: come indicato, è fortemente consigliata la creazione di una nuova classe (chiamata Valutatore in Listing 8).

Listing 8: Valutazione di espressioni semplici

```
import java.io.*;
public class Valutatore {
    private Lexer lex;
    private BufferedReader pbr;
   private Token look;
    public Valutatore(Lexer 1, BufferedReader br) {
       lex = 1;
        pbr = br;
        move();
    void move() {
        // come in Esercizio 3.1
    void error(String s) {
        // come in Esercizio 3.1
    void match(int t) {
        // come in Esercizio 3.1
    public void start() {
       int expr_val;
```

```
// ... completare ...
    expr_val = expr();
    match(Tag.EOF);
    System.out.println(expr_val);
    // ... completare ...
private int expr() {
    int term_val, exprp_val;
    // ... completare ...
    term_val = term();
    exprp_val = exprp(term_val);
    // ... completare ...
    return exprp_val;
private int exprp(int exprp_i) {
    int term_val, exprp_val;
    switch (look.tag) {
    case '+':
            match('+');
            term_val = term();
            exprp_val = exprp(exprp_i + term_val);
            break;
    // ... completare ...
}
private int term() {
   // ... completare ...
private int termp(int termp_i) {
   // ... completare ...
private int fact() {
   // ... completare ...
public static void main(String[] args) {
    Lexer lex = new Lexer();
    String path = "...path..."; // il percorso del file da leggere
        BufferedReader br = new BufferedReader(new FileReader(path));
        Valutatore valutatore = new Valutatore(lex, br);
        valutatore.start();
        br.close();
   } catch (IOException e) {e.printStackTrace();}
}
```

5 Generazione del bytecode

L'obiettivo di quest'ultima parte di laboratorio è di quello di realizzare un traduttore per i programmi scritti nel linguaggio di programmazione semplice, che chiameremo P, visto nell'esercizio 3.2. I file di programmi del linguaggio P hanno l'estensione .pas. Il traduttore deve generare bytecode [4] eseguibile dalla Java Virtual Machine (JVM).

Generare bytecode eseguibile direttamente dalla JVM non è una operazione semplice a causa della complessità del formato dei file .class (che tra l'altro è un formato binario) [3]. Il bytecode verrà quindi generato avvalendoci di un linguaggio mnemonico che fa riferimento alle istruzioni della JVM (linguaggio assembler [2]) e che successivamente verrà tradotto nel formato .class dal programma assembler. Il linguaggio mnemonico utilizzato fa riferimento all'insieme delle istruzioni della JVM [5] e l'assembler effettua una traduzione 1-1 delle istruzioni mnemoniche nella corrispondente istruzione (opcode) della JVM. Il programma assembler che utilizzeremo si chiama Jasmin (distribuzione e manuale sono disponibili all'indirizzo http://jasmin.sourceforge.net/).

La costruzione del file .class a partire dal sorgente scritto nel linguaggio P avviene secondo lo schema seguente:



Il file sorgente viene tradotto dal compilatore (oggetto della realizzazione) nel linguaggio assembler per la JVM. Questo file (che deve avere l'estensione . j) è poi trasformato in un file .class dal programma assembler Jasmin. Nel codice presentato in questa sezione, il file generato dal compilatore si chiama Output.j, e il comando java -jar jasmin.jar Output.j è utilizzato per trasformarlo nel file Output.class, che può essere eseguito con il comando java Output.

Significato delle istruzioni del linguaggio P.

$ID := \langle expr \rangle$

Assegna il valore dell'espressione $\langle expr \rangle$ all'identificatore rappresentato da ID. Ad esempio, x:=3 corrisponde all'assegnamento del valore 3 all'identificatore x.

print ($\langle expr \rangle$)

Stampa sul terminale il valore dell'espressione $\langle expr \rangle$. Ad esempio, print (2+3) stampa sul terminale il valore 5.

read (ID)

Permette l'inserimento di un numero intero dalla tastiera e l'assegnamento del valore del numero all'identificatore scritto tra parentesi. Ad esempio, il comando read (a) specifica che l'utente del programma scritto in linguaggio P deve inserire un numero intero con la tastiera, che poi è assegnato all'identificatore a.

case when ($\langle bexpr_1 \rangle$) $\langle stat_1 \rangle \cdots$ when ($\langle bexpr_n \rangle$) $\langle stat_n \rangle$ else $\langle stat \rangle$

Un comando condizionale: dall'elenco di espressioni booleane $\langle bexpr_1 \rangle \cdots \langle bexpr_n \rangle$, se la prima espressione che risulta valutata come vero è $\langle bexpr_k \rangle$ allora $\langle stat_k \rangle$ è eseguito, si esce dall'istruzione case e si procede alla prossima istruzione. Se nessuna espressione nell'elenco $\langle bexpr_1 \rangle \cdots \langle bexpr_n \rangle$ è verificata, viene eseguito lo $\langle stat \rangle$ scritto dopo la parola chiave else. Si noti che ogni $\langle stat_k \rangle$ può essere una singola istruzione oppure una sequenza di istruzioni racchiusa tra parentesi graffe; la stessa cosa vale per $\langle stat \rangle$. Ad esempio, l'istruzione

case when (x>0) {print (x); print (y)} when (y>0) print (y) else print (z)

stampa sul terminale i valori sia di x e y se il valore di x è maggiore di 0, solo il valore di y se il valore di x è uguale o inferiore a 0 e quello di y è maggiore di 0, e solo il valore di z se i valori sia di x che di y sono uguali o inferiori a 0.

while ($\langle bexpr \rangle$) $\langle stat \rangle$

Permette l'esecuzione ciclica di $\langle stat \rangle$. La condizione per l'esecuzione del ciclo è $\langle bexpr \rangle$. Come nel caso di case, si noti che $\langle stat \rangle$ può essere una singola istruzione oppure una sequenza di istruzioni racchiusa tra parentesi graffe. Ad esempio, l'istruzione

```
while (x>0) { x:=x-1; print (x) }
```

decrementa e stampa sul terminale il valore dell'identificatore \times , fino a quando \times ha il valore 0.

Classi di supporto. Per la realizzazione del compilatore utilizziamo le seguenti classi.

La classe OpCode è una semplice enumerazione dei nomi mnemonici (si veda [5] per un elenco dei nomi, ma utilizziamo solo quelli utili per la traduzione del linguaggio P). La classe Instruction verrà usata per rappresentare singole istruzioni del linguaggio mnemonico. Il metodo toJasmin restituisce l'istruzione nel formato adeguato per l'assembler Jasmin.

Listing 9: Una possibile implementazione della classe OpCode

```
public enum OpCode {
    ldc, imul, ineg, idiv, iadd,
    isub, istore, ior, iand, iload,
    if_icmpeq, if_icmple, if_icmplt, if_icmpne, if_icmpge,
    if_icmpgt, ifne, GOto, invokestatic, label }
```

Listing 10: Una possibile implementazione della classe Instruction

```
public class Instruction {
   OpCode opCode;
    int operand;
   public Instruction(OpCode opCode) {
        this.opCode = opCode;
   public Instruction(OpCode opCode, int operand) {
       this.opCode = opCode;
       this.operand = operand;
   public String toJasmin () {
        String temp="";
        switch (opCode) {
            case ldc : temp = " ldc " + operand + "\n"; break;
            case invokestatic :
               if( operand == 1)
                  temp = " invokestatic " + "Output/print(I)V" + "\n";
                  temp = " invokestatic " + "Output/read()I" + "\n"; break;
            case iadd : temp = " iadd " + "\n"; break;
            case imul : temp = " imul " + "\n"; break;
            case idiv : temp = " idiv " + "\n"; break;
            case isub : temp = " isub " + "\n"; break;
            case ineg : temp = " ineg " + "\n"; break;
            case istore : temp = " istore " + operand + "\n"; break;
            case ior : temp = " ior " + "\n"; break;
```

```
case iand : temp = " iand " + "\n"; break;
case iload : temp = " iload " + operand + "\n"; break;
case if_icmpeq : temp = " if_icmpeq L" + operand + "\n"; break;
case if_icmple : temp = " if_icmple L" + operand + "\n"; break;
case if_icmplt : temp = " if_icmplt L" + operand + "\n"; break;
case if_icmpne : temp = " if_icmpne L" + operand + "\n"; break;
case if_icmpge : temp = " if_icmpge L" + operand + "\n"; break;
case if_icmpgt : temp = " if_icmpgt L" + operand + "\n"; break;
case ifne : temp = " ifne L" + operand + "\n"; break;
case GOto : temp = " goto L" + operand + "\n"; break;
case label : temp = "L" + operand + ":\n"; break;
}
return temp;
}
```

La classe CodeGenerator ha lo scopo di memorizzare in una struttura apposita la lista delle istruzioni (come oggetti di tipo Instruction) generate durante la parsificazione. I metodi emit sono usati per aggiungere istruzioni o etichette di salto nel codice. Le costanti header e footer definiscono il preambolo e l'epilogo del codice generato dal traduttore per restituire, mediante il metodo toJasmin, un file la cui struttura risponde ai requisiti dell'assembler Jasmin.

Listing 11: Una possibile implementazione della classe CodeGenerator

```
import java.util.LinkedList;
import java.io.*;
public class CodeGenerator {
    LinkedList <Instruction> instructions = new LinkedList <Instruction>();
    int label=0;
   public void emit(OpCode opCode) {
        instructions.add(new Instruction(opCode));
   public void emit(OpCode opCode , int operand) {
        instructions.add(new Instruction(opCode, operand));
   public void emitLabel(int operand) {
       emit(OpCode.label, operand);
   public int newLabel() {
       return label++;
   public void toJasmin() throws IOException{
        PrintWriter out = new PrintWriter(new FileWriter("Output.j"));
        String temp = "";
       temp = temp + header;
        while(instructions.size() > 0){
            Instruction tmp = instructions.remove();
            temp = temp + tmp.toJasmin();
        temp = temp + footer;
        out.println(temp);
        out.flush();
```

```
out.close();
private static final String header = ".class public Output \n"
    + ".super java/lang/Object\n"
    + "\n"
    + ".method public <init>() V\n"
    + " aload_0\n"
    + " invokenonvirtual java/lang/Object/<init>() V\n"
    + " return\n"
    + ".end method\n"
    + "\n"
    + ".method public static print(I)V\n"
    + " .limit stack 2\n"
    + " getstatic java/lang/System/out Ljava/io/PrintStream; \n"
    + " iload_0 \n"
    + " invokestatic java/lang/Integer/toString(I)Ljava/lang/String; \n"
    + " invokevirtual java/io/PrintStream/println(Ljava/lang/String;)V\n"
    + " return\n"
    + ".end method\n"
    + "\n"
    + ".method public static read()I\n"
    + " .limit stack 3\n"
    + " new java/util/Scanner\n"
    + " dup\n"
    + " getstatic java/lang/System/in Ljava/io/InputStream; \n"
    + " invokespecial java/util/Scanner/<init>(Ljava/io/InputStream;)V\n"
    + " invokevirtual java/util/Scanner/next()Ljava/lang/String; \n"
    + " invokestatic java/lang/Integer.parseInt(Ljava/lang/String;)I\n"
    + " ireturn\n"
    + ".end method\n"
    + "\n"
    + ".method public static run() V\n"
    + " .limit stack 1024\n"
    + " .limit locals 256\n";
private static final String footer = " return\n"
    + ".end method\n"
    + ".method public static main([Ljava/lang/String;)V\n"
    + " invokestatic Output/run()V\n"
    + " return\n"
    + ".end method\n";
```

Per tenere traccia degli identificatori occorre predisporre una *tabella dei simboli*. Segue una possibile implementazione della classe SymbolTable:

Listing 12: Una possibile implementazione della classe Symbol Table

```
public class SymbolTable {
    Map <String, Integer> OffsetMap = new HashMap <String,Integer>();

    public void insert( String s, int address ) {
        if( !OffsetMap.containsValue(address) )
            OffsetMap.put(s,address);
        else
            throw new IllegalArgumentException("Riferimento ad una locazione di memoria gia' occupata da un'altra variabile");
```

```
public int lookupAddress ( String s ) {
    if ( OffsetMap.containsKey(s) )
        return OffsetMap.get(s);
    else
        return -1;
}
```

Esempi di generazione di bytecode. Seguono alcuni semplici programmi P affiancati dal bytecode JVM corrispondente.

Listing 13: B.pas

Listing 14: Bytecode di B. pas

```
read(a);
print(a+1)

istore 0

L1:
    iload 0
    ldc 1
    iadd
    invokestatic Output/print(I)V

L2:
    L0:
```

Listing 15: C.pas

Listing 16: Bytecode di C.pas

```
x := 10;
                                         ldc 10
y := 20;
                                         istore 0
z := 30;
                                        T.1:
                                         1dc 20
print (x + y * z)
                                         istore 1
                                        L2:
                                         1dc 30
                                         istore 2
                                        L3:
                                         iload 0
                                         iload 1
                                         iload 2
                                         imul
                                         iadd
                                         invokestatic Output/print(I) V
                                        L4:
```

Esercizio 5.1. Si scriva un traduttore per programmi scritti nel linguaggio P (utilizzando uno dei lexer sviluppati per gli esercizi di Sezione 2). Si ricorda che la grammatica del linguaggio P può essere trovato nell'esercizio 3.2.

Un frammento del codice di una possibile implementazione può essere trovato in Listing 17 (si nota che code è un oggetto della classe CodeGenerator).

Listing 17: Un frammento del codice di una possibile implementazione del programma di Esercizio 5.1

```
import java.io.*;
```

```
public class Translator {
   private Lexer lex;
   private BufferedReader pbr;
   private Token look;
   SymbolTable st = new SymbolTable();
   CodeGenerator code = new CodeGenerator();
   int count=0;
   public Translator(Lexer 1, BufferedReader br) {
       lex = 1;
       pbr = br;
       move();
   void move() {
       // come in Esercizio 3.1
   void error(String s) {
       // come in Esercizio 3.1
   void match(int t) {
       // come in Esercizio 3.1
   public void prog() {
        // ... completare ...
                int lnext_prog = code.newLabel();
                statlist(lnext_prog);
                code.emitLabel(lnext_prog);
                match(Tag.EOF);
                try {
                    code.toJasmin();
                catch(java.io.IOException e) {
                    System.out.println("IO error\n");
        // ... completare ...
   public void stat(int lnext) {
        switch(look.tag) {
        // ... completare ...
            case Tag.PRINT:
               match (Tag.PRINT);
                match('(');
                expr();
                code.emit(OpCode.invokestatic,1);
                match(')');
                break;
            case Tag.READ:
               match(Tag.READ);
                match('(');
                if (look.tag==Tag.ID) {
                    int read_id_addr = st.lookupAddress(((Word)look).lexeme);
```

```
if (read_id_addr==-1) {
                    read_id_addr = count;
                    st.insert(((Word)look).lexeme,count++);
                }
                match (Taq. ID);
                match(')');
                code.emit(OpCode.invokestatic,0);
                code.emit(OpCode.istore, read_id_addr);
            else
                error("Error in grammar (stat) after read( with " + look);
            break;
    // ... completare ...
// ... completare ...
private void b_expr(int ltrue, int lfalse) {
    // ... completare ...
    expr();
    if (look == Word.eq) {
         match(Tag.RELOP);
         expr();
         // ... completare ...
    // ... completare ...
// ... completare ...
private void exprp() {
    switch(look.tag) {
        case '+':
            match('+');
            term();
            code.emit(OpCode.iadd);
            exprp();
            break;
    // ... completare ...
// ... completare ...
```

Riferimenti bibliografici

- [1] Aho, Alfred V., Lam, Monica S., Sethi, Ravi, and Ullman, Jeffrey D. Compilatori: Principi, tecniche e strumenti. *Pearson Paravia Bruno Mondadori S.p.A.*, 2009.
- [2] Assembly language. http://en.wikipedia.org/wiki/Assembly_language Wikipedia, 2018.
- [3] Java class file. http://en.wikipedia.org/wiki/Java_class_file Wikipedia, 2018.
- [4] Java bytecode. http://en.wikipedia.org/wiki/Java_bytecode Wikipedia, 2018.
- [5] Java bytecode instruction listings. http://en.wikipedia.org/wiki/Java_ bytecode_instruction_listings Wikipedia, 2018.